

Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique

L'Université constantine 2
Faculté d'NTIC

Rapport de Travaux Pratiques

Apprentissage Automatique (Machine Learning)

Titre :

Étude comparative des méthodes d'extraction et de sélection de
caractéristiques pour la classification

Préparé par : Benaissa Roumeissa – Hamdane Salsabil

Encadrante : Ghanem Khadoudja

Année universitaire : 2025/2026

Contents

1	Introduction	4
1.1	Contexte du projet	4
1.2	Importance du domaine	4
1.3	Problématique	4
1.4	Solution proposée	5
1.5	Plan de travail	5
2	Exploration de dataset	6
2.1	Description de dataset	6
2.2	Description des features	6
2.3	Type de données pour chaque feature	7
2.4	Valeurs manquantes (Missing Values)	7
2.5	Distribution des classes	7
2.6	Analyse de la distribution des features et traitement des non-normalités	7
2.7	Détection et traitement des valeurs aberrantes	8
2.8	Corrélation des Features	8
3	Entraînement sans prétraitement	9
3.1	Comparaison des modèles de Machine Learning sans prétraitement	9
4	Prétraitement des données	10
4.0.1	Normalisation des données	10
4.0.2	Équilibrage des classes avec SMOTE	10
4.0.3	Réduction de dimension avec PCA	10
5	Features extraction	11
5.1	Sélection des variables importantes	11
5.2	Projection des données	11
5.2.1	Conclusion	11
5.3	Comparaison des modèles après PCA et sélection des features	12
5.3.1	Conclusion	12
6	Feature Selection	13
6.1	Les méthodes de Feature Selection	13
6.1.1	Chi-Square	13
6.1.2	Mutual Information et mRMR	14
6.1.3	6.1.3 Résultats comparatifs	14
6.1.4	Analyse	14
6.1.5	Conclusion	14

6.2	Méthode de wrapper	15
6.3	Les méthodes de Embedded	15
7	Combinaison des features	17
8	Conclusion	18

Résumé

Ce travail porte sur l'étude et la comparaison des méthodes d'extraction et de sélection de caractéristiques pour la classification de données biomédicales de haute dimension, appliquée à un dataset d'ovaire composé de 253 échantillons et de 15 154 caractéristiques spectrales (features MZ). En raison de la forte dimension des données et du faible nombre d'échantillons, différentes approches telles que la PCA, les méthodes filter, wrapper et embedded ont été explorées afin de réduire la redondance et d'améliorer les performances des modèles de classification. Plusieurs classifieurs ont été entraînés sur les sous-ensembles de caractéristiques sélectionnées afin d'évaluer leur efficacité. Les résultats expérimentaux montrent que les méthodes de sélection de caractéristiques surpassent la PCA en termes de précision et de stabilité. Cette étude met en évidence l'importance du choix des variables pertinentes pour améliorer la performance des modèles dans les problèmes biomédicaux à haute dimension.

Mots-clés : sélection de caractéristiques, extraction de caractéristiques, cancer de l'ovaire, données de haute dimension, classification, apprentissage automatique

Chapter 1

Introduction

1.1 Contexte du projet

Ces dernières années, l'analyse des données biomédicales est devenue un domaine central de l'intelligence artificielle et de l'apprentissage automatique, notamment dans les applications liées à la détection et au diagnostic du cancer. Parmi ces applications, la classification du cancer de l'ovaire à partir de données spectrales ou moléculaires suscite un intérêt croissant en raison de sa gravité et de la nécessité d'un diagnostic précoce et précis. Cependant, ces données sont souvent caractérisées par une très grande dimension et un nombre limité d'échantillons, ce qui rend la tâche d'apprentissage particulièrement complexe.

1.2 Importance du domaine

L'étude du cancer de l'ovaire est d'une grande importance dans le domaine biomédical en raison de son impact majeur sur la santé des femmes à travers le monde. Un diagnostic précoce et précis permet d'augmenter significativement les chances de survie et d'améliorer l'efficacité des traitements. Du point de vue de l'apprentissage automatique, ce domaine est également très intéressant car il implique des données de très haute dimension avec un nombre limité d'échantillons, ce qui en fait un cas d'étude idéal pour les techniques avancées de sélection et de réduction de dimension.

1.3 Problématique

Le principal défi de ce travail réside dans l'analyse et la classification de données biomédicales de très haute dimension, en particulier un dataset de cancer de l'ovaire composé de 253 échantillons et de 15 154 caractéristiques (features MZ). La grande disparité entre le nombre d'échantillons et la dimension des données rend l'apprentissage des modèles de classification difficile et peut entraîner des problèmes tels que le surapprentissage (overfitting), la redondance des variables et la faible capacité de généralisation. Ainsi, il est nécessaire d'appliquer des méthodes efficaces de réduction et de sélection de caractéristiques afin d'identifier les variables les plus pertinentes et d'améliorer les performances des modèles.

1.4 Solution proposée

Dans ce travail, nous proposons une étude comparative entre les méthodes d'extraction et de sélection de caractéristiques afin d'identifier les variables les plus pertinentes pour la classification. Nous étudions la PCA comme méthode d'extraction de caractéristiques, ainsi que plusieurs méthodes de sélection de caractéristiques telles que les approches filter, wrapper et embedded. Les caractéristiques sélectionnées sont ensuite utilisées pour entraîner différents classifieurs afin d'évaluer leurs performances et leur robustesse.

1.5 Plan de travail

Ce travail pratique est organisé comme suit :

1. Exploration du jeu de données
2. Prétraitement des données
3. Classification sans extraction ni sélection de caractéristiques
4. Application des méthodes d'extraction de caractéristiques
5. Application des méthodes de sélection de caractéristiques (Filter, Wrapper, Embedded)
6. Combinaison des features
7. Comparaison et discussion des résultats

Chapter 2

Exploration de dataset

2.1 Description de dataset

Le dataset utilisé contient des features haute-dimension destinées aux tâches de classification.

- Dataset : Ovarian Cancer Mass Spectrometry
- Source : <https://archive.ics.uci.edu/ml/datasets/Ovarian+Cancer>
- Nombre d'instances : 253 échantillons
- Nombre d'attributs : 15 154 features + 1 label (Class)
- Nombre de classes : 2 (Cancer, Normal)

2.2 Description des features

Le dataset contient 15 154 features numériques issues de l'analyse par spectrométrie de masse (Mass Spectrometry). Chaque feature est codée comme suit :

- Les colonnes commencent par “MZ” suivi d’une valeur flottante représentant le rapport masse/charge du signal détecté.
- Ces valeurs numériques correspondent à l’intensité mesurée d’un signal spécifique pour chaque échantillon.
- La dernière colonne, “Class”, indique le label de l’échantillon : “Cancer” ou “Normal”.

Exemple de noms de features :

```
['MZ-7.86E-05', 'MZ2.18E-07', 'MZ9.60E-05', 'MZ0.000366014',  
'MZ0.000810195', ..., 'MZ19995.513', 'Class']
```

Chaque ligne du dataset représente un échantillon de patient, et chaque colonne (à l'exception de “Class”) correspond à l’intensité d’un signal spécifique dans le spectre de masse.

2.3 Type de données pour chaque feature

- Le nombre de features de type `float64` est de 15 154, représentant les quantités mesurées des signaux m/z (protéines / peptides).
- Une seule colonne est de type `object`, correspondant à la colonne `Class`.

2.4 Valeurs manquantes (Missing Values)

Aucune valeur manquante n'a été détectée dans les colonnes, ce qui facilite le prétraitement des données (normalisation, standardisation, etc.).

2.5 Distribution des classes

- Cancer : 162 échantillons
- Normal : 91 échantillons




Figure 2.1: Enter Caption

Le dataset présente un déséquilibre entre les classes avec 162 échantillons *Cancer* (64%) et 91 échantillons *Normal* (36%). Ce déséquilibre peut biaiser les algorithmes d'apprentissage automatique en faveur de la classe majoritaire (*Cancer*).

2.6 Analyse de la distribution des features et traitement des non-normalités

Lors de l'analyse exploratoire des données, il a été observé que la majorité des features **ne suivent pas une distribution normale**. Ce phénomène est fréquent dans les données issues de la *mass spectrometry*, où l'intensité des signaux varie fortement d'une feature à l'autre.

Solution : Pour pallier ces problèmes et améliorer la performance des modèles de classification, il est recommandé de **normaliser** ou **standardiser les features** avant toute étape de réduction de dimensions .




Figure 2.2: Enter Caption

2.7 Détection et traitement des valeurs aberrantes

Nous avons détecté des **valeurs aberrantes (outliers)** dans nos données numériques à l'aide de la méthode de l'intervalle interquartile (IQR). Ces valeurs sont situées très loin de la majorité des données et peuvent biaiser l'analyse. Pour les traiter, on peut les supprimer, les remplacer (par mean , median) , transformer les données ou utiliser des modèles robustes.

2.8 Corrélation des Features

La matrice de corrélation montre deux informations importantes :

- La corrélation entre les features elles-mêmes, qui permet d'identifier les redondances ou les relations fortes entre certaines variables.
- La corrélation entre chaque feature et la classe (**Class_num**), qui indique quelles features sont les plus influentes pour la classification.

Une forte corrélation avec la classe suggère que la feature contribue significativement à la distinction entre les échantillons Cancer et Normal, tandis que les fortes corrélations entre features peuvent orienter le choix des méthodes de réduction de dimensionnalité ou de sélection de features.

Chapter 3

Entrainement sans prétraitement

3.1 Comparaison des modèles de Machine Learning sans prétraitement

Afin d'évaluer la performance de différents modèles de machine learning, quatre classificateurs ont été appliqués directement sur le dataset sans utiliser de techniques de prétraitement. Les modèles évalués sont : K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Decision Tree et Naive Bayes. L'évaluation a été réalisée en utilisant les métriques suivantes : Accuracy, Precision, Recall et F1-score.

Modèle	Accuracy	Precision	Recall	F1-score
KNN	0.9314	0.9265	0.9692	0.9474
SVM	0.9804	1.0000	0.9692	0.9844
Decision Tree	0.9118	0.9516	0.9077	0.9291
Naive Bayes	0.9020	0.9661	0.8769	0.9194

Table 3.1: Comparaison des performances des modèles sans prétraitement

D'après les résultats obtenus, le modèle Support Vector Machine (SVM) présente la meilleure performance avec une accuracy de 98.04% et un F1-score de 0.9844. Le modèle KNN montre également de bons résultats avec une accuracy de 93.14%. En revanche, les modèles Decision Tree et Naive Bayes présentent des performances légèrement inférieures par rapport à SVM et KNN.

Chapter 4

Prétraitement des données

Avant d'entraîner les modèles de classification, plusieurs étapes de prétraitement ont été appliquées afin d'améliorer la qualité des données et les performances des modèles.

4.0.1 Normalisation des données

La première étape consiste à normaliser les données. La normalisation permet de mettre toutes les variables sur la même échelle. Cette étape est importante car certaines variables peuvent avoir des valeurs beaucoup plus grandes que d'autres, ce qui peut influencer les modèles de machine learning. Dans ce travail, nous avons utilisé la standardisation afin de centrer les données autour de la moyenne et réduire l'effet des grandes valeurs.

4.0.2 Équilibrage des classes avec SMOTE

$x_{new} = x_i + \text{rand}(0,1) \times (x_j - x_i)$ Le dataset utilisé présente un déséquilibre entre les classes. Cela signifie qu'une classe possède plus d'échantillons que l'autre. Ce déséquilibre peut affecter la performance des modèles de classification.

Pour résoudre ce problème, nous avons utilisé la méthode SMOTE (Synthetic Minority Over-sampling Technique). Cette technique génère de nouveaux échantillons artificiels pour la classe minoritaire en utilisant les voisins les plus proches. Ainsi, le nombre d'échantillons dans chaque classe devient équilibré.

L'équilibrage des classes permet aux modèles d'apprendre correctement les caractéristiques des deux classes et d'améliorer la capacité de généralisation.

4.0.3 Réduction de dimension avec PCA

Le dataset contient un grand nombre de variables (features). Pour réduire la complexité des données et éliminer les informations redondantes, nous avons appliqué la méthode PCA (Principal Component Analysis).

PCA transforme les variables originales en nouvelles variables appelées composantes principales (Principal Components). Ces composantes représentent les directions qui contiennent le plus de variance dans les données.

Dans notre travail, nous avons sélectionné le nombre de composantes permettant de conserver 90% de la variance totale des données. Cela signifie que la majorité de l'information du dataset est conservée tout en réduisant le nombre de variables.

Chapter 5

Features extraction

5.1 Sélection des variables importantes

Après l'application de l'Analyse en Composantes Principales (ACP), nous avons choisi de conserver 90 % de la variance expliquée afin de préserver la majorité de l'information contenue dans le jeu de données tout en réduisant sa dimensionnalité. Ce seuil signifie que les composantes principales retenues expliquent 90 % de la variabilité totale des données, ce qui permet de garder l'information la plus pertinente tout en éliminant les redondances entre les variables. Par ailleurs, un seuil de poids (weight) de 40 % a été utilisé pour identifier et sélectionner les caractéristiques les plus importantes, c'est-à-dire celles qui contribuent le plus à la formation des composantes principales. À l'issue de ce processus, 12 composantes principales ont été retenues, représentant une version réduite mais informative du jeu de données, tout en conservant les informations essentielles nécessaires pour les étapes ultérieures d'analyse et de classification.

5.2 Projection des données

Après l'application de PCA, les données ont été projetées dans le nouvel espace formé par les composantes principales. Chaque échantillon du dataset est donc représenté par ses scores sur ces nouvelles composantes.

Cette projection permet de mieux visualiser la structure des données et d'observer la distribution des échantillons dans l'espace des composantes principales.

5.2.1 Conclusion

Les techniques de prétraitement appliquées dans ce travail — la normalisation des données, l'équilibrage des classes avec SMOTE et la réduction de dimension avec PCA — permettent d'améliorer la qualité des données et de faciliter l'apprentissage des modèles de classification.

5.3 Comparaison des modèles après PCA et sélection des features

Modèle	Accuracy	Precision	Recall	F1-score
SVM	0.971	0.98	0.96	0.97
KNN	0.951	0.96	0.94	0.95
Naive Bayes	0.951	0.96	0.94	0.95
Decision Tree	0.969	0.97	0.97	0.97

Table 5.1: Comparaison des performances des modèles après PCA et sélection des features

5.3.1 Conclusion

Après l'application de la réduction de dimension avec PCA et la sélection des features importantes, tous les modèles ont montré de bonnes performances. Le SVM obtient la meilleure accuracy (97,1%) et un F1-score de 0,97. Le Decision Tree suit avec une accuracy de 96,9%. KNN et Naive Bayes présentent une accuracy de 95,1%. Ces résultats confirment que la sélection des features essentielles permet de réduire la complexité des données tout en maintenant de hautes performances de classification.

Chapter 6

Feature Selection

6.1 Les méthodes de Feature Selection

Dans ce chapitre, nous avons appliqué trois méthodes principales de sélection des caractéristiques (Filter Methods) :

- Chi-Square
- Mutual Information
- mRMR (Minimum Redundancy Maximum Relevance)

6.1.1 Chi-Square

Nous avons utilisé la méthode **Chi-Square** pour évaluer la relation entre chaque caractéristique et la variable cible. Pour déterminer le nombre optimal de caractéristiques, nous avons testé deux approches :

1. **Sélection par un nombre fixe de caractéristiques** ($k = 70$) :
 - KNN : 0.9902
 - SVM : 0.9902
 - Arbre de décision : 0.9510
 - Naive Bayes : 0.9804
2. **Sélection par p-value** (SelectFpr avec $\alpha = 0.05$) :
 - KNN : 0.8922
 - SVM : 0.9608
 - Arbre de décision : 0.9216
 - Naive Bayes : 0.8725

6.1.2 Mutual Information et mRMR

La méthode **Mutual Information (MI)** mesure la dépendance entre chaque caractéristique et la variable cible. Elle permet de sélectionner les variables les plus informatives, même en présence de relations non linéaires. Cette méthode est particulièrement efficace avec des modèles comme KNN et SVM.

La méthode **mRMR (Minimum Redundancy Maximum Relevance)** vise à sélectionner des caractéristiques à la fois pertinentes pour la classification et peu redondantes entre elles. Elle permet de réduire la dimension des données tout en conservant un maximum d'information utile.

6.1.3 Résultats comparatifs

Méthode	KNN	SVM	Arbre de décision	Naive Bayes
Chi-Square ($k = 70$)	0.9902	0.9902	0.9510	0.9804
Chi-Square (p-value)	0.8922	0.9608	0.9216	0.8725
Mutual Information	0.9706	0.9608	0.9608	0.9804
mRMR	0.6667	0.9700	1.0000	1.0000

Table 6.1: Comparaison des performances des modèles selon différentes méthodes de sélection des caractéristiques.

6.1.4 Analyse

On remarque que :

- La méthode **Chi-Square avec k fixe** donne les meilleurs résultats globaux, surtout pour KNN et SVM.
- La méthode **Mutual Information** donne des résultats stables et performants pour tous les modèles.
- La méthode **mRMR** donne d'excellents résultats pour Decision Tree et Naive Bayes, mais une faible performance pour KNN.

6.1.5 Conclusion

Les deux meilleures méthodes selon nos expériences sont :

- **Chi-Square avec k choisi** : très fiable pour KNN et SVM.
- **Mutual Information** : efficace pour capturer des relations non linéaires.

Il est recommandé de combiner Mutual Information et mRMR afin d'obtenir des caractéristiques à la fois pertinentes et non redondantes.

6.2 Méthode de wrapper

Dans cette étape, nous avons utilisé la méthode Wrapper à travers l'algorithme SFS (Sequential Forward Selection), qui sélectionne progressivement les caractéristiques les plus pertinentes en fonction des performances du classificateur, afin d'optimiser la précision du modèle.

Table 6.2: Comparaison des performances des modèles de classification

Modèle	Accuracy	Precision	Recall	F1-score
KNN	0.96	0.95	0.97	0.96
SVM	0.98	0.99	0.97	0.98
Decision Tree	0.86	0.86	0.84	0.85
Naïve Bayes	0.94	0.93	0.94	0.94

D'après les résultats expérimentaux, le modèle **SVM** se distingue comme le meilleur classificateur, offrant les performances les plus élevées en termes de précision globale (accuracy) .

6.3 Les méthodes de Embedded

Embedded Methods c est une technique de features selection qui sélectionnent automatiquement les caractéristiques pertinentes au cours de l'entraînement du modèle en s'appuyant sur les poids ou l'importance des variables, combinant ainsi apprentissage et sélection de features de manière efficace. Les méthodes utilisées dans ce travail sont :

- **Decision Tree (DT)** : utilise les mesures d'impureté (Gini ou Entropie) pour évaluer l'importance de chaque feature pendant la construction de l'arbre.
- **Random Forest (RF)** : ensemble d'arbres de décision, qui fournit une importance moyenne des features, améliorant la robustesse et réduisant le risque d'overfitting.
- **SVM-RFE** (Support Vector Machine - Recursive Feature Elimination) : élimine récursivement les features les moins importantes en se basant sur les coefficients du SVM linéaire.
- **Lasso Regression** : utilise la régularisation L1 pour réduire certains coefficients à zéro, supprimant ainsi automatiquement les features moins importantes.

Table 6.3: Comparaison des performances des modèles

Modèle	Accuracy	Precision	Recall	F1-score
Decision Tree (DT)	0.9231	0.92	0.92	0.92
Random Forest (RF)	0.9923	0.99	0.99	0.99
Lasso	1.00	1.00	1.00	1.00
SVM-RFE	1.00	1.00	1.00	1.00

Les résultats expérimentaux montrent que, dans le cadre des méthodes de sélection de caractéristiques intégrées (*Embedded*), les modèles **Lasso** et **SVM-RFE** ont obtenu les meilleures performances, atteignant une exactitude parfaite (**Accuracy = 1.00**).

Comparaison globale des méthodes de sélection

Une analyse comparative des différentes approches de sélection de caractéristiques montre que, dans la catégorie *Filter*, la méthode **mRMR** a obtenu les meilleures performances. Concernant les méthodes *Wrapper*, l'algorithme **SFS (Sequential Forward Selection)** s'est révélé le plus efficace. Enfin, parmi les méthodes *Embedded*, **SVM-RFE** s'est distingué comme la technique la plus performante, offrant les meilleurs résultats .

Chapter 7

Combinaison des features

Après la phase de comparaison des méthodes de sélection de caractéristiques (Filter, Wrapper et Embedded), nous avons combiné les **top 30 features** issues des meilleures méthodes, à savoir **mRMR**, **SFS** et **SVM-RFE**. Cette fusion a permis d'obtenir un ensemble réduit de **8 caractéristiques** pertinentes.

Par la suite, un classement des features a été effectué en fonction de leur poids d'importance. Nous avons ensuite entraîné les différents classificateurs en testant progressivement des sous-ensembles allant de $n = 1$ à $n = 8$, afin d'identifier le nombre minimal de caractéristiques offrant les meilleures performances.

Les résultats expérimentaux ont montré que seulement **trois (3) features principales** influencent fortement les performances du modèle, à savoir : **MZ224.09159**, **MZ437.0239** et **MZ245.24466**. En utilisant ces caractéristiques, les classificateurs obtiennent d'excellents résultats, comme illustré dans le tableau, où plusieurs modèles atteignent une accuracy proche ou égale à 1.0, confirmant ainsi la pertinence des features sélectionnées.

Modèle	Accuracy
Logistic Regression	1.0
SVM	1.0
KNN	1.0
Naive Bayes	≈ 0.96
Decision Tree	≈ 0.99
Random Forest	≈ 0.99

Table 7.1: Résultats des modèles avec les 3 Top Features

Les véritables features ayant le plus d'impact sont présentées dans le tableau ci-dessous.

Feature
MZ224.09159
MZ437.0239
MZ245.24466

Table 7.2: Features les plus influentes sélectionnées après analyse

remarque : Nous avons également entraîné les modèles sur les 20 TOP features extrait de (PCA), mais les résultats obtenus n'étaient pas satisfaisants par rapport aux features sélectionnées initialement.

Chapter 8

Conclusion

Conclusion générale

Cette étude a permis de comparer plusieurs méthodes d'extraction et de sélection de caractéristiques appliquées à un problème de classification à haute dimension.

Les expériences réalisées montrent clairement que les méthodes de sélection de caractéristiques (filter, wrapper et embedded) donnent de meilleurs résultats que la PCA. En effet, les features sélectionnées de manière supervisée ont permis d'améliorer la performance du modèle en conservant uniquement les variables les plus discriminantes.

Limitation

Une limite importante de cette étude est la taille réduite du dataset, composé de seulement 253 échantillons pour 15154 features. Ce déséquilibre entre le nombre d'observations et la dimension des données peut influencer la généralisation des modèles et augmenter le risque d'overfitting.

Perspectives

Comme perspective, il serait intéressant de tester les modèles sur un dataset externe ou plus large afin de valider la robustesse des features sélectionnées. Cela permettrait également de confirmer la capacité de généralisation du modèle sur de nouvelles données.